

## HW06

Для доказательства факта того, что пересечение регулярного языка и КН-грамматики является КН-грамматикой, достаточно привести явный алгоритм построения КН-грамматики для пересечения. Этим мы и займёмся.

### Алгоритм

Нам даны автомат  $A$  и КН-грамматика  $G$ . Сразу будем считать, что  $G$  находится в НФ Хомского, потому что на лекциях было подробно разобрано, как любую КН-грамматику можно к ней привести.

Символами новой грамматики будем называть тройки вида  $(start, chain, end)$ , где  $start, end$  – какие-то вершины автомата  $A$ , а  $chain$  – нетерминал  $G$  такой, что ему будет соответствовать цепочка какого-то пути между  $start$  и  $end$  в автомате. Тогда начальным состояниям будут соответствовать тройки  $(A_{start}, G_{initial}, A_{terminal})$ . Для каждой такой тройки  $T_i$  добавим продукцию  $S : T_i$ .

Действительно, любая порождаемая автоматом цепочка начнётся в начальной вершине и закончится в терминальной, а любая цепочка из порождаемых КН-грамматикой начнётся с начального нетерминала.

Есть ещё один важный случай – грамматики, содержащие пустое слово. В терминах автоматов это означает, что стартовая вершина тоже является терминальной. Добавим такое правило –  $(A_{start}, G_{initial}, A_{start}) : \epsilon$ .

Научимся же строить такие тройки: все уже достигнутые состояния будем хранить в очереди. Сначала заполним её тройками  $(from, N, to)$ , где  $(from \rightarrow to)$  – какое-то ребро автомата  $A$ , а  $N$  – нетерминал, у которого есть правило, содержащее терминал. Таким образом, сначала мы рассмотрим все цепочки из одного символа, соответствующие правилам вида  $N : t$  в НФ Хомского. Это означает, что в дальнейшем мы с ними уже не встретимся. Теперь остались правила вида  $N : PQ$ : для их использования нам необходимо наличие троек  $(u, P, v), (v, Q, w)$ . Значит, мы будем последовательно исследовать нашу очередь и для текущего нетерминала рассматривать все правила, в которых он содержится. После извлечения обоих нетерминалов правило можно будет применить. Но нам нужно это как-то согласовать с автоматом. Для определённости будем считать, что последним мы вытащили  $Q$  в виде тройки  $(v, Q, w)$ . Тогда переберём вершины  $u$  и правила  $P$ , и если мы уже посетили  $(u, P, v)$ , то добавим новое достижимое состояние  $(u, N, w)$ . Для любой пары вершин автомата мы переберём все его вершины и все правила  $G$  – сложность выйдет  $O(|A|^3|G|)$ .

Теперь строго покажем, почему мы получили именно пересечение: пусть построенная нами  $G'$  породила некоторую цепочку  $x$ . Так как переходы мы делали только по правилам грамматики  $G$ , то  $x \in L(G)$ . Теперь найдём её в автомате: мы начинали в  $(start, \_, terminal)$ , а все переходы были вида  $(u, \_, w) : (u, \_, v)(v, \_, w)$  – то

есть они сохраняли связность пути в автомате. Значит наша цепочка соответствует некоторому пути в  $A$  между начальной вершиной и терминальной –  $x \in L(A)$ .

Теперь наоборот, надо по цепочке  $x$  из пересечения найти её в  $G'$ . Будем доказывать этот факт индукцией по  $|x|$ . Случаи с длинами 0, 1 были рассмотрены на этапе описания алгоритма – база есть. Будем показывать индукционный переход. Так как длина  $> 1$ , а цепочка принадлежит пересечению, то данную цепочку порождает некоторое правило  $N : PQ$ . Из принадлежности цепочки автомату мы можем заключить, что есть некоторый путь  $(u, \dots, w)$ , соответствующий  $x$ . Найдём в дереве разбора префикс  $p$ , соответствующий нетерминалу  $P$  из правила. Пусть этому префиксу соответствует вершина  $v$  в пути  $(u, \dots, w)$ . Теперь вспомним, что мы удалили все  $\epsilon$ -продукции, что означает, что каждый нетерминал породит непустую цепочку (если он, конечно, не  $\epsilon$ ). Следовательно, оба куска  $pq = x$  короче  $|x|$ , а, значит, по индукционному предположению, соответствующие им вершины  $(u, P, v), (v, Q, w)$  достижимы  $\Rightarrow$  получаемая из них вершина  $(u, N, w)$  тоже достижима. ЧТД.